Python for Data Analysis Projet

RAKAI Mohamed, RANDRIA Ntsoa, REINSBACH Eliot

Introduction

Notre dataset est un jeu de données de 130 hôpitaux aux USA. Ce dataset réunit les données de 1999 à 2008.

Présentation du dataset

Est-ce que la prise de médicaments permet de réduire les risques de réadmission des patients







0

Les étapes principales

preparation

- Exploration
- Nettoyage
- Mapping

Visualization

- Graphiques simples
- Graphiques ayant nécessité un mapping
- Résumé en histogrammes

Machine Learning

- Encodage
- Pipeline
- Entrainement

Exploration


0 0	0	▶ df.head(5)									
	<u>=</u>		race	gender	age	weight	admission_type_id	discharge_disposition_id	admission_source_id	time_in_hospital	
		0	Caucasian	Female	[0-10)	NaN	6	.25		1	
		1	Caucasian	Female	[10-20)	NaN		1	7	3	
		2	AfricanAmerican	Female	[20-30)	NaN		1	7	2	
		3	Caucasian	Male	[30-40)	NaN		15	7	2	
		4	Caucasian	Male	[40-50)	NaN	1		7	1	
		5 ro	ws × 48 columns								


insulin	glyburide- metformin	glipizide- metformin	glimepiride- pioglitazone	metformin- rosiglitazone	metformin- pioglitazone	change	diabetesMed	readmitted
No	No	No	No	No	No	No	No	NO
Up	No	No	No	No	No	Ch	Yes	>30
No	No	No	No	No	No	No	Yes	NO
Up	No	No	No	No	No	Ch	Yes	NO
Steady	No	No	No	No	No	Ch	Yes	NO

Nettoyage


- Suppression des colonnes inexploitables
- Mise en forme des colonnes
- Vérification des données en double

Rate of Missing Values by	Columns:
race	2.233555
gender	0.000000
age	0.000000
weight	96.858479
admission_type_id	0.000000
discharge_disposition_id	0.000000
admission source id	0.000000
time in hospital	0.000000
payer_code	39.557416
medical_specialty	49.082208





def tranche_age(texte):
 nombres = re.findall(r'\d+', texte)
 nombres = list(map(int, nombres))
 return (sum(nombres)/2)



Mapping 1

- Récupération d'un fichier.txt sur les codes IC9
- Enregistrement sous forme de pré-dictionnaire

```
Entrée [286]: premapping diag = {}
             with open("file1.csv", 'r', encoding='ISO-8859-1') as file:
                 next(file) # pour ignorer L'en-tête
                 for line in file:
                     icd9code, long_description, = line.strip().split(',')[:3]
                     premapping diag[icd9code] = long description
              for key, value in premapping diag.items():
                 print (key, value)
            003.9 Salmonella infection - unspecified
            004.0 Shigella dysenteriae
            004.1 Shigella flexneri
            004.2 Shigella boydii
            004.3 Shigella sonnei
            004.8 Other specified shigella infections
            004.9 Shigellosis - unspecified
            005.0 Staphylococcal food poisoning
            005.1 Botulism food poisoning
            005.2 Food poisoning due to Clostridium perfringens (C. welchii)
            005.3 Food poisoning due to other Clostridia
```

Mapping 1 (suite)

- Mise en forme des codes ICD9 dans un dictionnaire
- · Rajout de valeurs manquantes

```
mapping_diag = ()
for old_key, value in premapping diag.items():
     new key = old key.lstrip("0") # Supprime les zeros inutiles au début du nombre. exemple : 806 voudru W
    nk v2=re.sub(r'\.05', '', new key)# Supprime Les '.0' inutiles on fin de chaîne, exemple : 130.0 vaudra 120 nk v2=re.sub(r'\.005', '', nk v2)# Supprime Les '.00' inutiles on fin de chaîne, exemple : 130.00 vaudra 130
     nk_v2=re.sub(r'\.5', ", nk_v2)# Supprise Les "." en fin de chaîne.
     1# ', in nk v2:
        nk v2- nk v2.rstrip("0") #supprime Le dermier chiffre quand c'est un zéro si et seulement si Le nombre est un nombre à :
     mapping diag[nk v2] = value # Ajoute La nouvelle clé et su value correspondante dans le nouveau dictionnaireif '.' in nk i
for key, value in supping diag.items():
     print (key, value)
Cholera due to vibrio cholerae
1.1 Cholera due to vibrio cholerae el tor
1.9 Cholera - unspecified
2 Typhoid fever
2.1 Paratyphoid fever A
2.2 Paratyphoid Fever B
2.3 Paratyphoid fever C
2.9 Paratyphoid fever - unspecified
i Salmonella gastroenteritis
3.1 Salmonella septicemia
3.2 totalized salmonella infection - unspecified
```

Mapping 2

Extraction de données depuis le fichier IDS.csv


Mapping 2 (suite)


```
admissions_lit = []
mauvaises_valeurs=[]
for value in df['admission_type_id']:
    if str(value) in admission.keys():
        admissions_lit.append(admission[str(value)])
    else:
        admissions_lit.append(0)
        mauvaises_valeurs.append(value)

df['admission_type'] = admissions_lit

# on verifie les valeurs manquantes
valeurs_uniques = set(mauvaises_valeurs) #on convertit en set car il n'y a pas 2 fois la même valeur dans un set
print(valeurs_uniques)
set()
```


Graphiques simples 1





Résultats scientifiques 11

Graphiques simples 2




0

```
df_=df.copy()
df_['age']=df_['age'].apply(tranche_age).astype(int)
df_time_by_age = (df_.groupby('age')['time_in_hospital'].mean()).sort_values(ascending=False)
#print(df_time_by_age)
df_time_by_age.plot.barh()
plt.xlabel('nombre de jours')
plt.title("nombre de jours moyen en fonction de l'âge")
```


Résultats scientifiques 12

Graphiques Mapping 1

Encoding: fonction tranche_age Mapping




```
df_=df.copy()
mapping = {"<30":1,">30":1,"no":0}
df_['readmitted']=df_['readmitted'].map(mapping)
readmitted_by_race = df_.groupby('race')['readmitted'].sum().reset_index(name='count')
```



Graphiques Mapping 2


Mapping ICD9




Résumé graphiques 1




Résumé graphiques 2



Ordinal encoding vs onehot encoding






Algorithmes d'apprentissage supervisé

0

SMV vs Random Forest vs KNN


Support Vector Machine (SVM)




Random Forest



K-Nearest Neighbors (KNN)



Résultats



0

Résultats scientifiques



